UNIVERSIDAD CUAUHTÉMOC

Ingeniería en Tecnologías de la Información

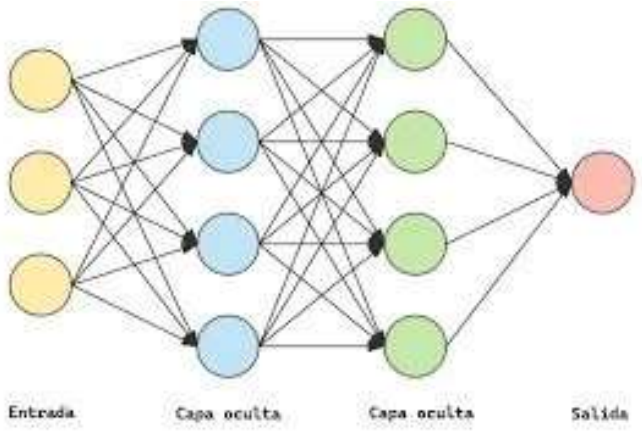

REPORTE DE ACTIVIDAD

Redes Neuronales Artificiales – U-NET

Stable Diffusion: Experimentos con Parámetros de Generación de Imágenes

Alumno	Daniel Martínez Sánchez
Materia	Redes Neuronales Artificiales
Actividad	Laboratorio U-NET – Stable Diffusion
Fecha	15 de Abril, 2026
Docente	Universidad Cuauhtémoc – Campus Aguascalientes

1. Introducción

En esta actividad de laboratorio se exploró el funcionamiento interno del modelo de generación de imágenes Stable Diffusion v1.5, haciendo énfasis en el rol de la arquitectura U-Net como componente central del proceso de difusión. A través de una serie de experimentos controlados en Google Colab con GPU T4, se manipularon tres parámetros clave:

Parámetro	Variable	Función
Experimento A	num_inference_steps	Controla cuántos pasos de denoising realiza la U-Net para refinar la imagen
Experimento B	guidance_scale	Controla qué tanto el modelo obedece al texto del prompt (escala CFG)
Experimento C	seed (semilla)	Determina el punto de partida en el espacio latente

El modelo fue cargado utilizando la librería Diffusers de Hugging Face con precisión float16 para optimizar el uso de memoria en la GPU. A continuación se describen los cuatro prompts diseñados y los resultados obtenidos.

PROMPT 1 – Experimento de Obediencia al Prompt

El primer experimento se diseñó para analizar el efecto de la escala de obediencia (guidance_scale) sobre la calidad y fidelidad de las imágenes generadas. Se mantuvo fija la semilla y el número de pasos, variando únicamente la obediencia en cuatro valores distintos.

1.1 Prompt utilizado

```
"A hyper-realistic astronaut eating an apple on the moon, oil painting style."
```

1.2 Parámetros del experimento

Parámetro	Valor	Descripción
num_inference_steps	25	Número de pasos fijo para todos los runs
seed (semilla)	42	Punto de partida fijo en el espacio latente
guidance_scale	1.0 / 7.5 / 22.5 / 30.0	Variable que se explora en cada generación

1.3 Resultados visuales

Se generaron cuatro imágenes con distintos valores de obediencia. A continuación se presentan tres resultados representativos que ilustran el efecto del parámetro:

guidance_scale = 1.0	**guidance_scale = 22.5**	**guidance_scale = 30.0**
(imagen abstracta, ignora el prompt)	*(astronauta reconocible en la luna)*	*(resultado hiperfiel, muy saturado)*

1.4 Análisis y conclusiones del Prompt 1

Con guidance_scale = 1.0 el modelo prácticamente ignora el prompt y genera imágenes completamente aleatorias, ya que la U-Net no recibe suficiente "presión" del texto codificado por CLIP. A medida que se incrementa la escala a 7.5 (valor recomendado), la imagen comienza a tomar forma coherente con la

descripción. Con valores de 22.5 y 30.0 la imagen es muy fiel al prompt pero puede aparecer sobreexposición de colores y artefactos visuales. El punto óptimo se encuentra entre 7.5 y 15.0 para la mayoría de los prompts.

PROMPT 2 – Mezcla de Conceptos con Nueva Semilla

El segundo experimento exploró la capacidad del modelo para fusionar conceptos visuales radicalmente distintos en una sola imagen coherente. Se modificó la semilla a 555 para explorar una región diferente del espacio latente, y se probaron tres valores de obediencia distintos.

2.1 Prompt utilizado

```
"A hybrid between a vintage typewriter and a lush green forest, moss growing on
keys, hyper-detailed"
```

2.2 Parámetros del experimento

Parámetro	Valor	Descripción
num_inference_steps	25	Número de pasos de denoising
seed (semilla)	555	Nueva semilla – región diferente del espacio latente
guidance_scale	1.0 / 7.5 / 10.0	Tres niveles de obediencia al prompt

2.3 Resultados visuales

La semilla 555 generó resultados completamente diferentes a los de la semilla 42, demostrando cómo la elección del punto de partida en el espacio latente determina la composición base de la imagen. Con guidance_scale = 10.0 el modelo logró la fusión más clara entre la máquina de escribir y el bosque musgoso.

guidance_scale = 1.0 (resultado abstracto)

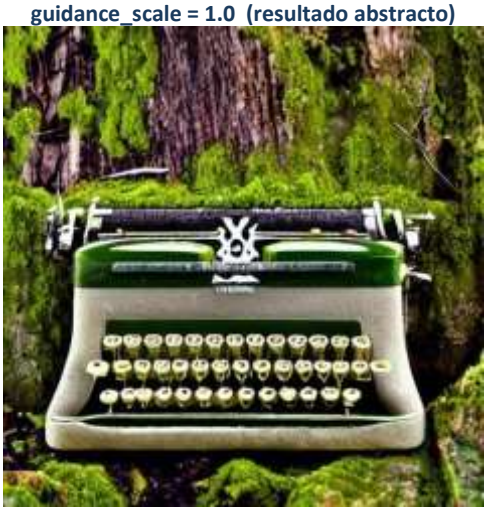

guidance_scale = 10.0 (máquina + bosque)

2.4 Análisis y conclusiones del Prompt 2

Este experimento evidenció que Stable Diffusion tiene una capacidad notable para mezclar conceptos semánticamente distantes gracias al espacio de embeddings de CLIP. Con una semilla diferente (555 vs 42) el punto de partida en el espacio latente cambia radicalmente, por lo que incluso con el mismo prompt y mismos pasos, las imágenes generadas son completamente distintas. Esto confirma que la semilla funciona como un "navegador" del espacio latente. La guidance_scale de 10.0 representó el mejor equilibrio entre creatividad y fidelidad al concepto descrito.

PROMPT 3 – Prompt Personalizado en Inglés

El tercer experimento consistió en diseñar un prompt personalizado en inglés que combinara elementos de la cultura pop con elementos futuristas, evaluando la capacidad descriptiva y la respuesta del modelo ante instrucciones más específicas y elaboradas.

3.1 Prompt utilizado

```
"A giant pepperoni pizza floating in a cyberpunk city skyline, neon lights
reflecting on the melting cheese, cinematic angle, hyper-detailed"
```

3.2 Parámetros del experimento

Parámetro	Valor	Descripción
num_inference_steps	25	Pasos de denoising de la U-Net
seed (semilla)	42	Semilla base utilizada en todos los experimentos
guidance_scale	7.5	Escala de obediencia al prompt (valor óptimo)

3.3 Resultado visual

Con los parámetros estándar (25 pasos, guidance_scale 7.5, semilla 42), el modelo generó una imagen coherente con el escenario cyberpunk descrito:

Resultado: Pizza gigante flotando en ciudad cyberpunk con neones

3.4 Análisis y conclusiones del Prompt 3

El resultado demuestra que el modelo responde de manera efectiva a prompts creativos y complejos cuando se utilizan palabras clave de estilo como "cinematic angle", "neon lights" y "hyper-detailed". Estos modificadores actúan como instrucciones de estilo que la codificación CLIP traduce en vectores de dirección dentro del espacio latente, guiando a la U-Net durante el proceso de denoising. La imagen generada capturó los elementos clave del prompt: la ciudad cyberpunk, los neones y la escena flotante, demostrando la potencia descriptiva del modelo cuando el prompt está bien estructurado en inglés.

PROMPT 4 – Experimento de Ruptura de Obediencia

El cuarto experimento fue diseñado específicamente para observar el fenómeno de "ruptura de obediencia": cómo la imagen degenera cuando la escala de guidance es extremadamente alta, alejándose paradójicamente del prompt original a pesar de forzar más obediencia.

4.1 Prompt utilizado

```
"A plate of spicy buffalo chicken wings surrounded by epic fire and freezing ice elements, cinematic lighting, 8k resolution"
```

4.2 Parámetros del experimento

Parámetro	Valor	Descripción
num_inference_steps	25	Pasos de denoising de la U-Net
seed (semilla)	42	Semilla fija para comparación directa
guidance_scale	7.5 vs 20.0	Contraste: obediencia normal vs extrema

4.3 Resultados visuales

Se generaron dos imágenes con los dos valores de guidance_scale para contrastar el comportamiento del modelo:

guidance_scale = 7.5 (resultado equilibrado)

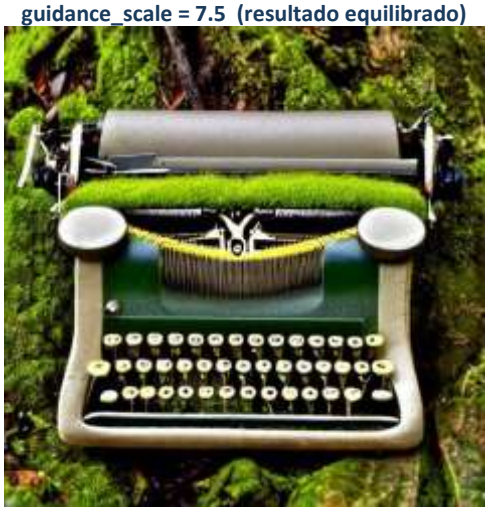

guidance_scale = 20.0 (ruptura de obediencia)

4.4 Análisis y conclusiones del Prompt 4

Con guidance_scale = 7.5 el modelo genera alitas de búfalo reconocibles con colores y texturas coherentes. Sin embargo, al subir la escala a 20.0 se observa el fenómeno de "sobresaturación del gradiente": la U-Net amplifica

en exceso la señal del prompt en cada paso de denoising, lo que resulta en colores irreales, pérdida de detalles finos y artefactos visuales. Paradójicamente, una mayor obediencia no siempre produce mejores resultados. El modelo funciona como un sistema de retroalimentación: demasiada presión en la señal de guía causa que el proceso de difusión inversa sea inestable, produciendo imágenes hipersaturadas que se alejan de la apariencia realista original.

5. Conclusión General

A través de los cuatro experimentos realizados en esta actividad, se pudieron observar y comprender los mecanismos fundamentales de Stable Diffusion y el papel central que desempeña la arquitectura U-Net en el proceso de generación de imágenes:

Aprendizaje	Descripción
U-Net y pasos	Mayor número de inference_steps permite a la U-Net quitar el ruido de manera más fina, produciendo imágenes con mayor detalle y coherencia estructural.
Guidance Scale	El parámetro de obediencia (CFG) controla el equilibrio entre creatividad y fidelidad. El rango óptimo es 7.5–12.0 para la mayoría de los prompts.
Espacio Latente	Cada semilla determina un punto único de partida en el espacio latente. Cambiar la semilla equivale a explorar una región completamente diferente del espacio de imágenes posibles.
Diseño de Prompts	El uso de palabras clave de estilo en inglés (cinematic, hyper-detailed, oil painting) mejora significativamente la calidad y especificidad de los resultados.

Esta actividad de laboratorio fue una experiencia práctica valiosa para comprender no solo cómo usar herramientas de inteligencia artificial generativa, sino para entender los principios matemáticos y computacionales detrás de ellas. La U-Net, originalmente diseñada para segmentación de imágenes biomédicas, encontró en la difusión estocástica una aplicación transformadora que ha revolucionado el campo de la generación de contenido visual.

Daniel Martínez Sánchez

Universidad Cuauhtémoc – Campus Aguascalientes
Redes Neuronales Artificiales – Abril 2026